心屿 MindIsle

对话陪聊 + 情感陪伴的 AI 网页应用

本地微调情绪模型 × 三级共识路由 × 3D 情绪叙事

2026 第八届全球校园人工智能算法精英大赛 · 算法创新赛 · 赛题 2「AI+软件创新」

团队成员：＿＿＿＿＿＿（队长）、＿＿＿＿＿＿、＿＿＿＿＿＿

在线演示：https://xinyu-soulisle.pages.dev

大学生情绪困扰高频常在，但现有产品"只聊天、不感知、看不见"

24.1%

18～24 岁人群抑郁风险检出率（心理健康蓝皮书 2021–2022），显著高于其他年龄组

只聊天

不识别情绪，回复与状态无关——"我很难过"换来通用话术

不感知

情绪不被结构化抽取，无法驱动策略、渲染与统计

看不见

说完就忘，没有趋势与记忆，陪伴关系无法积累

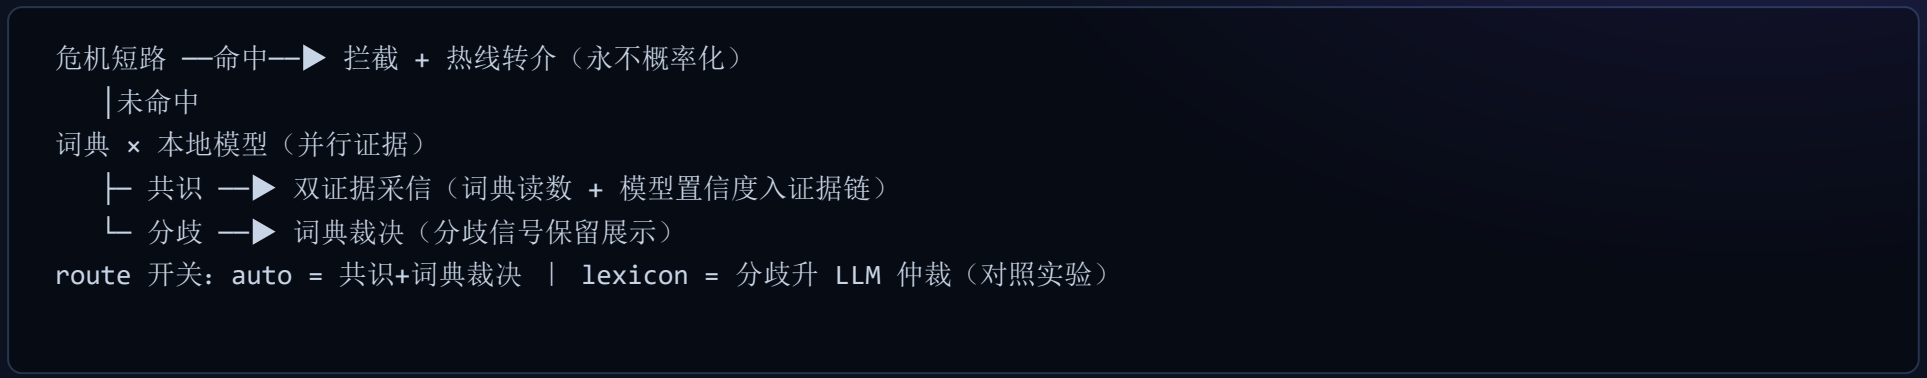
我们的切入点：把情绪变成系统里可计算、可呈现、可追溯、可安全兜底的一等公民。

一条情绪数据流，串起识别 → 生成 → 呈现 → 记忆 → 安全

用户输入 —▶ ① 感知层 · 三级情绪路由
⓪ 危机词短路（确定性规则，不调用任何模型）
① 词典快判（≈0ms，可解释，离线）
② 本地微调模型（chinese-roberta-wwm-ext，26.6ms，离线）
③ 大模型精判（可选仲裁，route 开关切换）
—▶ ② 决策/生成层：情绪条件化提示 + 近10轮上下文 + SSE 流式
—▶ ③ 呈现层：情绪 → 3D 星雾颜色/粒子点亮（无 WebGL 降级渐变）
—▶ ④ 记忆层：情绪曲线（本机默认，可清除可导出）

判定路径随每条回复逐条展示——**不是"模型说它理解了"，而是把每一路的证据摆出来。**

三级共识路由：把"模型准不准"变成可切换、可实测的工程问题



结构性永不倒退

共识与分歧的最终读数都锚定词典 ⇒ 升级模型腿不改写既有准确率。73 条评测实测：离线/在线**双口径 98.6% 恒等**（72/73）。

现场可切换

route 开关就是两种仲裁策略的对照实验——答辩现场一键切换，证据标签随之变化。

成本与延迟三档

词典 μs 级 / 模型 26.6ms / LLM 647ms；共识语义下 LLM 调用次数降为 **0**，演示可全程拔网线。

危机安全边界永不概率化 ｜ 情绪驱动的 3D 可视化

危机：规则优先于生成

- 命中危机词表 → **跳过全部生成逻辑**，直接返回专业热线（12356 等）
- 不交给模型随机性，不在该路径等待网络
- 实测危机召回 **6/6**；盲测 6 条危机改写句恰好证明规则层的必要

情绪被看见

- 主情绪定主色，次情绪达主情绪分值 40% 才渲染第二色（防噪声）
- 对话、星雾、曲线共享同一条情绪数据流
- 离线降级**诚实标注**：绝不用模板冒充在线 AI

网页离线可用（Service Worker 应用壳）：对标 16 个同类开源项目，**零同类实现**——会场断网也能演完。

不是调 API：本机微调的中文情绪模型，从数据管道到服务化全链路自建

数据（无泄漏断言放行）

train **3622** 条

SMP2020-ECDT 公开底料映射 1500 + DeepSeek 生成校园域对抗样本 2122（self-consistency 过滤）

dev 970 / blind 237（冻结，零交集）

训练（本机 GPU）

chinese-roberta-wwm-ext · 6 epoch

RTX 5070 Ti 实测 **约 5 分钟**

dev 宏 F1 **0.890**

服务化

FastAPI 推理服务

Java ModelProxy 接入三级路由

单条推理 **26.6 ms**，完全离线、零按次成本

含否定/程度对抗专项语料（"没什么好难过的""我一点都不紧张"）——第一版模型正是栽在这些句子上，补语料后重训。

评委可现场复跑：一条命令、一个 URL，数字当场重算

基准	词典	本地微调模型	LLM（云端）	三级路由（上线）
73 条自建评测（词典主场）	**98.6%**	86.6%	—	**98.6%（双口径恒等）**
237 条冻结盲测（口语生成域）	46.3%	**92.2% / 26.6ms**	**97.0% / 647ms**	46.3% / 30.5ms
危机召回	**6/6（短路层）**	0/6*	0/6*	**6/6**

* 模型/LLM 未训危机类——危机由规则短路层专职负责。

两个基准结论相反 = **域偏移的量化证据**，也是我们下一步改进的第一优先级（见 P11）。

现场可复跑项：**GET /api/emotion/eval**（评测重算）· route 开关切换 · 拔网线演示 · 逐条判定路径标签

两个被我们自己的实验否决的设计

否决 ①：模型高置信主判

设想让微调模型直接主判。实测模型单腿在词典主场仅 86.6%（miss 集中在否定/程度对抗句）⇒ 会倒退。

结论：回退为共识语义，词典可解释性 × 模型语义鲁棒性以双证据组合。

否决 ②：分歧升 LLM 仲裁

在线实测把 10 条分歧升给 LLM：73 条在线 98.6% → 94.5%（LLM 错 4 条）。

结论：上线词典裁决；LLM 仲裁保留为 route=lexicon 可切换语义，开关即对照实验。

我们不回避失败实验——被否决的路径和否决它的数据，本身就是工程严谨性的证据。

可验证性是设计出来的，不是承诺出来的

101

JUnit 用例全绿（Mockito 桩 + blackHole 断言模型腿不触网）

97% / 95%

行 / 分支覆盖率，低于阈值构建即失败（守卫脚本复算）

1:1

前后端契约对账 + 词表单一真相源三层比对（防两端静默分叉）

三路部署全在线

Cloudflare Pages（主）· 腾讯云 CloudBase（备）· Docker 482MB / fat jar（私有化，可带本地模型）

安全基线

密钥零落前端、零入库（服务端环境变量/云端 secret）；镜像内密钥扫描 CLEAN；危机拦截规则化

诚实降级

大模型不可用 → 离线模板并明示；模型腿未配置 → 行为与旧双路完全一致（增强项而非依赖项）

场景明确，社会价值真实

场景	价值	付费方
高校心理健康中心	咨询前后的轻量前置倾诉入口；可（经合规授权）查看群体情绪态势	学校 / 院系
班级 / 社团	期末、考研季等高压时段的情绪自测与疏导	学校 / 社团
个人用户	隐私优先的情绪陪伴与长期记录（默认本机存储，不上传）	个人订阅

隐私本位：**对话与情绪记录默认留在本机**——校园场景对"不想被别人知道"极为敏感，这是产品力而非负担。

我们清楚自己差在哪，也知道往哪走

当前不足	改进方向
域偏移：词典裁决保证不倒退，但域外口语表达可能误判（盲测词典 46.3% vs 模型 92.2%）	按域自适应加权：词典无命中且模型高置信时采信模型，同时保留 73 条评测为回归硬门
危机词表盲区：6 条改写句仅命中 2 条	扩充危机词表 + 改写样本回归（安全层改进，最高优先级）
尚未开展真实用户试点	免费在线版积累真实反馈 → 高校心理中心合规试点
生成层依赖第三方大模型	判定已不依赖云端；生成层接入本地开源模型作降级选项

欢迎现场验证以下任何一项

- **复跑评测**：`GET /api/emotion/eval` —— 73 条逐条结果与 98.6% 当场重算
- **策略对照**：route 开关切换 auto / lexicon，判定路径标签随之变化
- **拔网线**：断网后五幕叙事与本地引擎对话照常可用，徽章如实降级
- **危机拦截**：输入危机表达 → 立即返回 12356 等热线，不生成对话
- **证据链**：每条回复展示判定路径 + 生成模式 + 真实耗时

心屿 MindIsle

让情绪被识别、被看见、被记住、被安全兜底。

谢谢评委 —— 在线演示：https://xinyu-soulisle.pages.dev